TWAGIRUMUKIZA

人工智能在 SOC 告警分诊中的作用：IT 卫生、零信任与工具碎片化的调节效应

Innocent Twagirumukiza · 2026 年 10 月



每一条线代表一条告警，只有少数是真正的信号。

摘要

人工智能（AI）对安全运营中心（SOC）告警分诊的影响，取决于其所部署环境的质量。本文提出一个概念框架来检验这一论点。研究问题为：IT 卫生（信息技术卫生）的成熟度、零信任（Zero Trust）实施的一致性以及工具碎片化的程度，是否以及如何改变 AI 相对于传统分诊在检测质量和调查成本上的效应。

该框架区分了信息量与信息噪声。它将 AI 的使用视为核心变量，将上述三个因素视为调节变量，将告警数量和规则配置复杂度视为控制变量。文章提出四项研究命题，每项均给出预期方向及其证伪标准。本文提出一个三阶段的验证方案：可复现的针对性综述、探索性定性研究，以及辅以已标注告警受控回放的多层次分析。

本文不报告任何实证结果。其目的是提供一个可检验的基础，以判断在何种条件下 AI 能够真正降低信息噪声，而不是将既有缺陷自动化。

关键词： SOC；告警分诊；信息噪声；人工智能；IT 卫生；零信任；工具碎片化；调节效应；人类决策。

1. 引言

安全运营中心（SOC）集中承担监控、检测、分析和事件响应工作。它们依托安全事件管理、终端检测、威胁情报和响应编排等解决方案。云环境的增多、数字身份的普及以及遥测数据来源的增长，使需要处理的数据量不断增加，而各组织则堆叠专用工具，以覆盖日益扩大的范围。

文献描述了这一状况对人的影响。Tariq 等（2025）梳理了 SOC 中告警疲劳的研究现状。Alahmadi 等（2022）与 Kokulu 等（2019）基于对分析师的访谈，报告了与告警相关性以及工具、流程和人员之间匹配度有关的困难。Vielberth 等（2020）对 SOC 及其尚未解决的挑战进行了系统研究。Ofte 与 Katsikas（2023）考察了操作人员的态势感知。

面对这些困难，AI 越来越多地被视为告警优先级排序、关联和摘要的杠杆。为此，Chhetri 等（2024）研究了分析师与 AI 之间的协作。但 AI 被嵌入的是一个已经成型的环境，其中有既定的检测规则、工具和安全实践，没有任何理由认为其贡献在不同 SOC 之间是相同的。

1.1 拟填补的研究空白

上述研究大多考察告警负荷、人机协作或态势感知。AI 的效应与技术和组织环境质量之间的关联，则较少被形式化。本文的工作假设是：这一空白确实存在，且意义重大；第 5 节所述的针对性综述须在投稿前对此予以证实或证否。

分诊 AI 需要消费上下文：资产标识、资产所有者、账户历史、补丁状态、终端安全态势，以及来自多个工具的日志。如果这些上下文不完整、不一致或分散，AI 可能运行得更快，却未必决策得更好。反之，受控良好的环境则可能使 AI 产生真实的收益。因此，上下文并非单纯的混杂变量：它可能决定了我们试图测量的效应。

1.2 研究问题

IT 卫生成熟度、零信任实施的一致性以及工具碎片化程度，如何改变 AI 相对于传统分诊在 SOC 告警分诊中对检测质量和调查成本的效应?

该问题分解为三个子问题：

1. SQ1（卫生）。 当 IT 卫生更为成熟时，AI 相对于传统分诊的优势是否更为显著?
2. SQ2（碎片化）。 当工具碎片化且互操作性较差时，这一优势是否减弱，抑或 AI 反而弥补了这种碎片化?
3. SQ3（零信任）。 对于与身份和访问相关的告警，一致的零信任实施是否会增强 AI 的优势?

两项结果须一并考察：以漏掉威胁为代价换取的时间节省，并不构成改进。

1.3 贡献与结构

本文提供三项内容：一是区别于信息量和告警疲劳的信息噪声功能性定义；二是以 AI 为核心变量、以环境的三项特征为调节变量的调节框架；三是四项可证伪的命题及相应的验证方案。第 2 节回顾文献，第 3 节介绍框架，第 4 节提出命题，第 5 节阐述验证方法，第 6 至 8 节分别为讨论、局限与结论。

2. 文献综述

本综述有意聚焦于支撑该模型的内容。它仍属初步性质：第 5 节计划在投稿前开展可复现的综述。

2.1 告警数量与疲劳

告警疲劳是指，当分析师处理大量相关性较低或难以确定相关性的告警时，可能出现的注意力或警觉性下降（Tariq 等，2025）。告警数量衡量的是负荷，而非工作的难度：两个收到相同数量告警的 SOC，可能因可用上下文、冗余程度和调查程序的不同而面临截然不同的工作量。因此需要区分所采集事件的数量、所生成告警的数量、相关告警的占比、定性的难度以及最终决策的质量。

2.2 分诊中的 AI 与人机协作

AI 可以对告警进行优先级排序、关联事件、概括上下文并自动化重复性任务。Chhetri 等（2024）主张采用这样一种协作：由自动化处理适合的任务，而人类专业能力则留给模糊的案例。然而，关于自动化的研究表明，过度信任和自满是已知的风险（Parasuraman 与 Riley，1997；Parasuraman 与 Manzey，2010）。因此，只有当漏掉相关威胁的风险没有增加时，AI 以更短时间处理更多告警才会改善安全。这一保留意见说明，应当将调查成本与检测质量一并测量。现有评估也指向同一方向，但存在局限。一项在某高校 SOC 中针对八

张工单的试验由工具设计者自己开展，报告八例中有七例分诊更快（Banstola 等，2026）。一种多智能体架构在可处置告警上取得了高于简单智能体的 F1，但中位延迟高出三倍以上（Wei 等，2025）。一项针对六种安全编排、自动化与响应（SOAR）工具的用户研究发现效率提高，但工单的准确性和完整性下降（Bridges 等，2023）。一项面向 696 名分析师的混合方法调查表明，自动化会减少监控并提高对其输出的信任，而系统性的核验程序可以缓解这一风险（Tilbury 与 Flowerday，2026）。最后，一项涵盖 87 项告警过滤与分诊研究的综述指出，仅有九项基于真实 SOC 数据或实际部署，已发表的结果应视为上限（Ndichu 等，2026）。

2.3 工具碎片化与上下文丢失

SOC 组合了多种专用技术。这种多样性提高了覆盖面，却可能削弱集成度：同一资产使用不同的标识、告警冗余、需要跨多个界面手动重建上下文。Kokulu 等（2019）基于 18 次访谈，记录了 SOC 中技术、流程与人员之间的错位；所涉 SOC 均没有将其工具整合在一起的统一界面。相关变量并非产品数量，而是互操作性、数据的语义一致性以及组件之间的上下文共享。由许多集成良好的工具构成的环境，在本模型意义上并不碎片化。

2.4 IT 卫生

IT 卫生涵盖维持环境受控的基本实践：资产清单、补丁管理、账户与权限管理、安全配置。ANSSI（2017）提出了相应的措施参考框架。对于 SOC 而言，这些实践决定了一条告警能够多容易地关联到某项资产和责任人，以及基线行为的稳定性。然而，卫生状况的改善可能揭示此前不可见的事件，并暂时增加检测数量；因此预期效应涉及的是告警的可解释性，而非其数量。一项关于 SOC 困难的概念性分析，将缺少持续维护的流程、文档不完整和信息流不足，与可能长达三至六个月的规则调优联系起来（Onwubiko 与 Ouazzane，2019）；这是间接线索，而非测量结果。

2.5 零信任

零信任（Zero Trust）建立在对访问的显式验证、最小权限，以及对每次请求的上下文与风险评估之上（Rose 等，2020）。CISA（2023）的成熟度模型将其实施划分为若干支柱，其中包括身份和终端。相关控制措施产生关于身份、设备和访问条件的信息，这些信息与其他来源相关联后，有助于对访问类告警进行定性。但协调不佳的策略也可能使拒绝次数和上下文切换成倍增加。因此，零信任既不是噪声的内在来源，也不是降低噪声的保证。在本模型中，它的作用仅限于与身份和访问相关的告警，在这类告警中它提供上下文。

2.6 综合与当前依据

下表针对模型的每个要素，列出其假定作用以及本文目前拥有的文献依据程度。它凸显了需要通过针对性综述予以巩固的部分。

要素	模型中的假定作用	当前文献依据
告警疲劳与数量	控制变量	充分（Tariq 等，2025；Alahmadi 等，2022）
人机协作	辅助分诊的框架	部分（Chhetri 等，2024；Parasuraman 与 Manzey，2010；Tilbury 与 Flowerday，2026）；评估主要基于公开数据集（Ndichu 等，2026）
工具碎片化	调节变量	部分，主要为定性研究（Kokulu 等，2019）
IT 卫生	调节变量	有参考框架（ANSSI，2017），有间接线索（Onwubiko 与 Ouazzane，2019），关于其与 SOC 关联的研究较少

要素	模型中的假定作用	当前文献依据
零信任	调节变量，身份与访问告警	有参考框架（Rose 等，2020；CISA，2023），关于其与 SOC 关联的研究较少
这些因素与 AI 之间的交互	贡献的核心	初步探索中未发现相关研究；有待通过针对性综述确立

因此，空白与其说是每个因素各自缺乏文献，不如说是据一次未查询任何学术数据库的初步探索（2026 年 10 月），缺乏一个将它们作为 AI 对分诊效应的调节变量加以整合的框架。

3. 概念框架

3.1 信息噪声的定义

信息噪声是指在特定运营情境下，安全信息中占用分析资源、却未能与其占用成比例地有助于识别、定性或管理相关威胁的那一部分。

这一定义是功能性的。非恶意的告警不一定是噪声：它可能验证某项控制的覆盖范围，或揭示配置错误。噪声需要结合调查的目的、信号的价值以及利用该信号所需的工作量来判断。它有别于信息量（一种数量），也有别于告警疲劳（反复暴露于难以应对的负荷之下可能产生的一种人的后果）。

3.2 模型变量

模型提出的是一个差值问题：AI 是否比传统分诊做得更好或成本更低，且这一差值是否随环境而变化？模型包含一个核心变量、三个调节变量、两项结果以及一组控制变量。下图给出其结构，下表给出操作性定义。

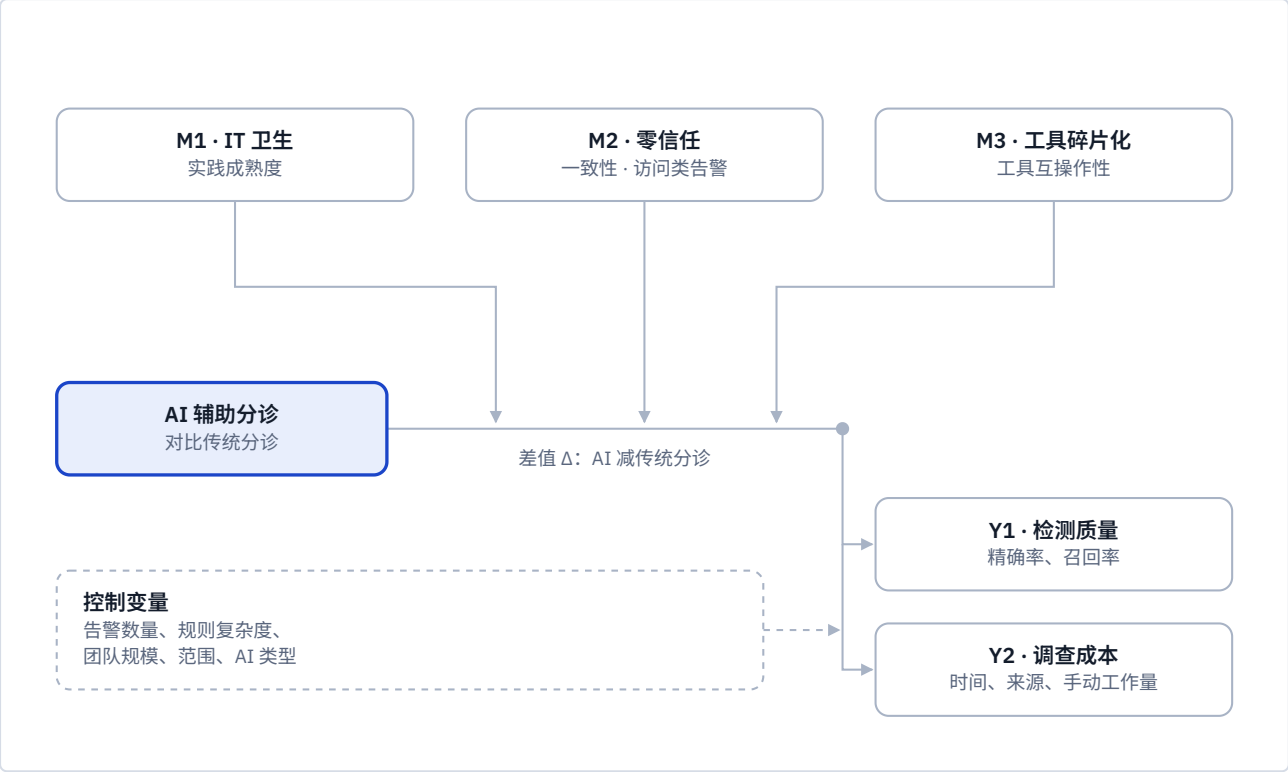


图 1. 调节模型：一个核心变量、三个调节变量、两项结果。

三个调节变量作用于 AI 与传统分诊之间的差值，而非直接作用于结果；控制变量则作用于所比较的两种条件。

角色	变量	操作性定义
核心	AI 辅助分诊	使用 AI 对告警进行优先级排序、关联或摘要，与基于规则和手动程序的传统分诊相比较。以其功能、自动化程度和人工监督来描述。
调节变量 M1	IT 卫生成熟度	资产清单的完整性、补丁合规性、账户与权限的受控程度、配置的维护情况。
调节变量 M2	零信任实施的一致性	访问策略的协调统一，以及身份和终端数据的集成。应用于与身份和访问相关的告警。
调节变量 M3	工具碎片化	实际互操作性较低：同一资产没有共同标识、上下文分散、每条告警需查阅的界面数量。
结果 Y1	检测质量	相关告警上的精确率、召回率和漏报率。
结果 Y2	调查成本	定性所需时间、所查阅的来源数量、每条告警的手动工作量。
控制	数量与配置	告警数量、规则配置复杂度、团队规模与经验、受监控范围、AI 类型。

3.3 对模型的解读

设 Δ 为 AI 辅助分诊与传统分诊之间的性能差值，分别在 Y1 和 Y2 上测量。调节变量是使 Δ 发生变化的变量：AI 的效应并不被假定为恒定，而被假定为有条件的。该模型并不断言 AI 总体上有效或无效；它说明的是其效应在何处、在何种条件下发生变化。

以下三点说明对这一解读加以限定。

1. **成熟度与一致性是两个不同的构念。** 卫生以实践的成熟度来衡量，零信任则以架构及其策略的一致性来衡量。二者将分别加以操作化（第 5 节）。
2. **数量与规则复杂度是控制变量，而非研究对象。** 它们在所比较的两种条件下均影响告警负荷，但本框架并不试图解释其自身的效应。
3. **存在竞争性解读。** 卫生也可能作为改变告警数量的因素发挥作用（直接效应），而最成熟的 SOC 可能正是最先采用 AI 的那些（选择偏差）。第 5 节的方案规定了同一 SOC 内部的比较，以限制后一种风险。

4. 研究命题

以下四项命题是有待检验的理论陈述，而非结果。每项命题均说明预期效应、作用机制以及何种情形将证伪它。“AI 的优势”针对每项结果，指相对于传统分诊而言有利于 AI 的差值：更高的检测质量或更低的调查成本。

P1 基准效应：收益首先体现在成本上

命题陈述。 平均而言，AI 辅助分诊相对于传统分诊降低了调查成本（Y2），但这一降低不足以确立检测质量（Y1）的改善，后者的差值可能为零、为正或为负。

作用机制。 AI 首先通过优先级排序和摘要来提高定性的速度。检测质量取决于排序的准确性以及掩盖重要告警的风险，这是决策辅助系统已知的风险（Parasuraman 与 Manzey，2010）。现有评估将速度的提升与工单准确性和完整性的下降联系在一起（Bridges 等，2023），因此不能从 Y2 的下降推断 Y1 的改善。

证伪条件。 若 AI 下的成本并不更低，或者 Y1 上的优势在所有环境中均一致为正（这将使区分两项结果失去意义），则 P1 被证伪。

P2 IT 卫生：优势随成熟度提高而增大

命题陈述。 在控制告警数量的条件下，IT 卫生成熟度（M1）越高，AI 在 Y1 和 Y2 上的优势越大。

作用机制。 完整的资产清单、受控的账户和稳定的配置，使 AI 能够将每条告警关联到某项资产和责任人，并依托稳定的基线行为。

注意。 更好的卫生状况可能揭示此前不可见的事件，并暂时增加检测数量；因此需要控制告警数量。

证伪条件。 在控制数量之后，AI 的使用与 M1 之间的交互为零或符号相反。

P3 工具碎片化：优势减弱，或 AI 予以弥补

命题陈述。 工具越碎片化、互操作性越差（M3），AI 在 Y1 和 Y2 上的优势越小。

作用机制。 不一致的标识和分散的上下文限制了 AI 关联数据的能力；其输出因而建立在不完整的上下文之上。

竞争性命题。 相反，AI 也可能通过关联分析师否则须逐一查阅的分散来源，来弥补碎片化。在这种情况下，优势在碎片化的环境中会更为显著。这两种解读相互对立，且可通过数据加以区分；对二者作出判别是本研究可能的贡献。

证伪条件。 AI 的使用与 M3 之间的交互为零或为正。正向交互将支持竞争性解读。

P4 零信任：对访问类告警，优势随一致性提高而增大

命题陈述。 对于与身份和访问相关的告警，零信任实施（M2）越一致（即策略得到协调统一，且身份和终端数据已集成），AI 在 Y1 和 Y2 上的优势越大。

作用机制。 零信任控制为定性访问类告警提供了可利用的上下文：终端安全态势、会话风险、所适用的访问决策。

注意。 协调不佳的策略可能使拒绝次数和上下文切换成倍增加，并削弱零信任对分诊的贡献。

证伪条件。 这些告警上不存在交互，或者与访问无关的告警上存在相同幅度的交互。后一种情形表明，所测量的构念反映的是总体成熟度，而非零信任。

综合

命题	因素	对 AI 优势的预期效应	涉及的告警
P1	无（基准效应）	Y2 上有优势；Y1 上的优势尚未确立	全部
P2	M1 IT 卫生	随成熟度提高而增大	全部
P3	M3 工具碎片化	随碎片化加剧而减小（竞争性解读：增大）	全部
P4	M2 零信任	随一致性提高而增大	身份与访问

三个调节变量的叠加（高阶交互）未被表述为命题：它在第 7 节中作为探索性问题处理。

5. 拟议的验证方法

验证按三个阶段依次展开，从最具探索性到最具约束性。一条共同的逻辑贯穿其中：在卫生、零信任和碎片化程度各不相同的情境内部，比较 AI 与传统分诊。

5.1 阶段 0。可复现的针对性综述

将开展一项范围有限的系统综述，依据 PRISMA 2020（Page 等，2021）进行报告，以核实第 1.1 节所提出的空白。它将检索 SOC、告警分诊、AI、IT 卫生、零信任与工具集成之间的交叉领域，并记录数据库、检索式、纳入标准和筛选过程。其结果决定了贡献的最终表述。

5.2 阶段 1。探索性定性研究

将对 SOC 分析师、检测负责人、首席信息安全官（CISO）以及工具集成专家开展半结构化访谈。建议的目标为在 4 至 6 个不同的 SOC（内部、服务提供商、公共部门和私营部门）中进行约 12 至 20 次访谈，直至达到主题饱和。访谈将核实调节变量是否对应于真实的机制、操作性定义是否可操作，并收集 AI 帮助或妨碍分诊的案例示例。

5.3 阶段 2。多层次分析与受控回放

多层次分析。 告警（第 1 层）嵌套于 SOC 或客户范围（第 2 层）之中。调节变量 M1、M2 和 M3 在第 2 层测量；在可能的情况下，AI 的使用在同一 SOC 内部发生变化（部署前后、使用与不使用 AI 的处理队列）。估计包含第 1 层与第 2 层之间交互项的混合效应模型（Raudenbush 与 Bryk，2002；Hayes，2018）。第 2 层交

互的统计功效取决于 SOC 或范围的数量，而非告警的数量。如果该样本量不足以估计三个交互，研究将只保留两个调节变量；而托管服务提供商同时监管多个成熟度水平不同的客户，构成了一个值得探索的自然变异来源。

受控回放。 由专家标注的告警数据集作为基准真值。分析师在有或无 AI 辅助的条件下对其进行处理，并改变所提供上下文的质量（资产清单完整或降级、标识共用与否、身份数据是否集成）。这一操纵使我们能够逼近调节变量对 AI 优势的因果效应，而仅凭生产数据无法确立这一点。注入的场景（例如来自攻击模拟演练的场景）补充了该设计，用以估计召回率，而召回率在生产环境中是不可观测的。根据 Ndichu 等（2026），目前没有公开数据集同时包含真实分析师的判定、调查元数据和纵向上下文；因此回放数据集需要自行构建，或与合作 SOC 协商获取。

基于 GUIDE 的探索性校准。 公开数据集 GUIDE（Freitas 等，2024）将 SOC 告警与分析师的判定（真阳性、良性阳性、假阳性）关联起来，但不包含 M1、M2、M3 的任何测量，也不包含调查成本：因此它无法检验 P2 至 P4。对来自 480 个组织、约 1750 起事件的摘录所作的探索性检查表明，判定在组织层面高度聚集（组内相关系数约为 0.7，基于至少有两起事件的组织估计，不确定性较大）。这一数值支持采用多层次分析，同时提醒我们，判定既反映环境，也反映各 SOC 的评级习惯，仅凭这些数据无法将二者区分。它还表明，决定本研究统计功效的，是组织数量，而非告警数量。

5.4 操作化

构念	拟采用的指标	来源
AI 辅助分诊	受辅助的功能、自动化程度、人工监督、被修正的建议占比	访谈、工具日志
M1 卫生	受 ANSSI（2017）措施启发的综合得分：资产清单覆盖率、补丁合规性、账户与权限审查	审计、资产管理数据
M2 零信任	受 CISA（2023）模型的身份和终端支柱以及 Rose 等（2020）原则启发的量表：策略一致性、数据集成	审计、架构文档
M3 碎片化	每条告警所查阅的界面数量、在共同标识下得到解析的资产占比、获取上下文的时延	观察、日志
Y1 检测质量	精确率、召回率、漏报率	标注数据集、注入场景
Y2 调查成本	定性时间中位数、交叉查阅次数、手动工作量	日志、计时
控制	告警数量、规则复杂度、团队规模与经验、范围、AI 类型	运营数据

指标将在数据收集之前确定。只有当召回率没有下降时，告警数量或处理时间的减少才会被解释为收益。

5.5 分析策略

描述性分析将刻画数量、分布以及不同情境之间的差异。混合效应模型将检验 AI 的使用与每个调节变量之间的交互，设置按 SOC 划分的随机效应并纳入控制变量；P4 将仅在身份与访问告警上估计，然后与其他告警进行比较，作为特异性检验。敏感性分析将改变指标的定义，多重比较将予以校正。由于 AI 的部署并非随机，且最成熟的 SOC 可能最先采用它，因此成熟度被显式建模，并优先采用 SOC 内部比较。在数据收集之前，不能预期任何结果。

5.6 伦理与保密

告警数据具有敏感性，可能包含个人数据。研究将要求与各组织签订保密协议、对日志进行匿名化或假名化，并对处理时间使用汇总数据，以避免对分析师个人进行评价。访谈将取得知情同意。

6. 讨论

6.1 理论贡献

该框架将研究问题从数量转向 AI 的条件性价值。它不是问 AI 是否减轻了告警疲劳，而是问在何种情境下它能改善检测并降低调查成本。这一重新表述带来三点后果。

1. **AI 被视为嵌入环境之中的处理能力，而非孤立的解决方案。** 其效应是有条件的，而被检验的正是这种条件性。
2. **生产率的提高并不等于安全性的提高。** 通过同时测量 Y1 和 Y2，该框架避免了对一种缩短处理时间却放过更多威胁的 AI 得出其表现良好的结论。
3. **竞争性解读从一开始就被提出。** 就碎片化而言，P3 及其竞争性命题预测了相反的符号，这使该框架在从业者直觉出现分歧的问题上具有可证伪性。

6.2 对网络安全治理的启示

安全与 SOC 负责人可以从该框架中得到一个诊断框架，供其在投资 AI 层之前使用。所观察到的困难是源于校准不当的规则、不完整的资产清单、失控的账户、无法互操作的工具，还是缺乏程序？如果答案出在环境上，AI 就有可能带来速度的提升而无检测上的收益，并使其所自动化的缺陷更难被发现。

该框架还建议，在数量指标之外补充相关性、上下文、定性成本和决策绩效方面的度量，并将模糊的案例保留给人工监督。它并不反对创新：它试图确定创新在何种条件下能带来可衡量的改进。

6.3 投资的先后次序

如果 P2 和 P4 得到验证，IT 卫生和零信任的一致性就不只是独立的安全目标：它们还提高了检测类 AI 投资的回报。如果 P3 得到支持，工具集成应先于 AI。如果是竞争性命题占上风，AI 则反而可以成为碎片化的短期缓解手段。无论哪种情形，投资决策都宜建立在对情境的诊断之上，而不是仅仅依赖工具的承诺。

7. 局限与展望

7.1 局限

- **稿件性质。** 本文为概念性文章。它不依赖任何原始数据，其命题尚未确立。文献综述是初步的，须由阶段 0 的可复现综述取代。
- **构念效度。** 卫生、零信任一致性和碎片化都是复合构念，其测量取决于情境。所提议的量表受参考框架（ANSSI，2017；CISA，2023）启发，而这些框架并非为测量 AI 效能的调节变量而设计，须加以验证。
- **零信任的适用范围。** 调节变量 M2 仅适用于身份与访问告警。它对其他类别告警的分诊没有任何说明。
- **基准真值。** 精确率和召回率需要关于相关事件的可靠基准。在生产环境中，召回率不可观测，只能依赖注入的场景，而其代表性有限。
- **选择与因果。** AI 的部署并非随机。SOC 内部比较和受控回放限制了偏差，但无法将其消除。

- **AI 的异质性。** 机器学习分类器、关联引擎和基于语言模型的助手，其优势与缺陷各不相同，且演进迅速。AI 类型是一个控制变量，但其结果未必能从一代工具推广到另一代工具。
- **推广性。** 内部 SOC、服务提供商和公共机构在资源和目标上各不相同。比较时必须将此考虑在内。

7.2 展望

- **高阶交互。** 三个调节变量的效应是相互叠加、相互抵消，还是其中一个便已足够？这一问题具有探索性，需要比首次研究更大的样本。
- **时间维度。** 成熟度是不断演进的。纵向研究可以追踪当卫生、零信任或工具集成得到改善时 AI 优势的变化。
- **人的因素。** 人工监督、过度信任和自满对 Y1 的影响，可以作为额外的中介变量或调节变量加以建模。系统性核验程序可缓解监控的下降（Tilbury 与 Flowerday，2026），是此处未纳入的候选调节变量。
- **对手的适应。** 分诊 AI 可能成为攻击目标。将该框架扩展到针对检测的攻击下的稳健性，值得专门研究。

8. 结论

本文提出，将对告警疲劳的分析从数量转向人工智能的条件性价值。它提出了一个明确的问题：IT 卫生、零信任的一致性和工具碎片化是否以及如何改变 AI 对分诊的效应，具体体现在检测质量和调查成本上。

核心命题是：AI 在 SOC 中的运营价值，不仅取决于其自身能力，还取决于其所处环境在配置、集成和上下文化方面的质量。四项可证伪的命题（其中一项使关于碎片化效应的两种解读相互对立）以及一个三阶段方案，使这一命题得以接受检验。

如果它得到验证，那么在增加一层 AI 之前应当提出的问题，就不再仅仅是工具能够做什么，而是环境允许它做什么。如果它被证伪，该框架至少也将厘清 AI 在何种条件下能够不受情境影响而带来可衡量的收益，这同样会是一个有用的结果。

参考文献

Agence nationale de la sécurité des systèmes d'information (ANSSI). (2017). *Guide d'hygiène informatique : renforcer la sécurité de son système d'information en 42 mesures* (version 2.0). ANSSI.

Alahmadi, B. A., Axon, L., & Martinovic, I. (2022). 99% false positives: A qualitative study of SOC analysts' perspectives on security alarms. *Proceedings of the 31st USENIX Security Symposium*. USENIX Association.

Banstola, K., Al Faisal, F., & Ou, X. (2026). Experiences of using agentic AI to fill tooling gaps in a Security Operations Center. *Workshop on Security Operation Center Operations and Construction (WOSOC 2026)*. NDSS Symposium. https://www.ndss-symposium.org/wp-content/uploads/wosoc26-02.pdf

Bridges, R. A., et al. (2023). *Testing SOAR tools in use* (arXiv:2208.06075). https://arxiv.org/abs/2208.06075

Chhetri, M. B., Tariq, S., Singh, R., Jalalvand, F., Paris, C., & Nepal, S. (2024). Towards human-AI teaming to mitigate alert fatigue in Security Operations Centres. *ACM Transactions on Internet Technology, 24*(3), Article 12, 1–22. https://doi.org/10.1145/3670009

Cybersecurity and Infrastructure Security Agency (CISA). (2023). *Zero Trust Maturity Model, Version 2.0*. CISA.

Freitas, S., Kalajdjieski, J., Gharib, A., & McCann, R. (2024). *AI-driven guided response for Security Operation Centers with Microsoft Copilot for Security* (arXiv:2407.09017). https://arxiv.org/abs/2407.09017

Hayes, A. F. (2018). *Introduction to mediation, moderation, and conditional process analysis: A regression-based approach* (2nd ed.). Guilford Press.

Kokulu, F. B., Soneji, A., Bao, T., Shoshitaishvili, Y., Zhao, Z., Doupé, A., & Ahn, G.-J. (2019). Matched and mismatched SOCs: A qualitative study on Security Operations Center issues. *Proceedings of the 2019 ACM SIGSAC Conference on Computer and Communications Security*. ACM.

Ndichu, S., Ban, T., Ozawa, S., Takahashi, T., & Inoue, D. (2026). *AI-driven security alert screening and alert fatigue mitigation in Security Operations Centers: A survey* (arXiv:2605.08316). https://arxiv.org/abs/2605.08316

Ofte, H. J., & Katsikas, S. (2023). Understanding situation awareness in SOCs: A systematic literature review. *Computers & Security, 126*, 103069. https://doi.org/10.1016/j.cose.2022.103069

Onwubiko, C., & Ouazzane, K. (2019). Challenges towards building an effective Cyber Security Operations Centre. *International Journal on Cyber Situational Awareness, 4*(1), 11–39.

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., et al. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ, 372*, n71. https://doi.org/10.1136/bmj.n71

Parasuraman, R., & Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors, 52*(3), 381–410.

Parasuraman, R., & Riley, V. (1997). Humans and automation: Use, misuse, disuse, abuse. *Human Factors, 39*(2), 230–253.

Raudenbush, S. W., & Bryk, A. S. (2002). *Hierarchical linear models: Applications and data analysis methods* (2nd ed.). Sage.

Rose, S., Borchert, O., Mitchell, S., & Connelly, S. (2020). *Zero Trust Architecture* (NIST Special Publication 800-207). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.800-207

Tariq, S., Baruwal Chhetri, M., Nepal, S., & Paris, C. (2025). Alert fatigue in Security Operations Centres: Research challenges and opportunities. *ACM Computing Surveys, 57*(9), Article 224, 1–38. https://doi.org/10.1145/3723158

Tilbury, J., & Flowerday, S. V. (2026). The vigilance paradox: Automation reliance inside the modern SOC. *Information & Computer Security, 34*(4), 639–662. https://doi.org/10.1108/ICS-08-2025-0318

Vielberth, M., Böhm, F., Fichtinger, I., & Pernul, G. (2020). Security Operations Center: A systematic study and open challenges. *IEEE Access, 8*, 227756–227779.

Wei, B., Tay, Y. S., Liu, H., Pan, J., Luo, K., Zhu, Z., & Jordan, C. (2025). *CORTEX: Collaborative LLM agents for high-stakes alert triage* (arXiv:2510.00311). https://arxiv.org/abs/2510.00311

© 2026 Innocent Twagirumukiza。初步版本，2026 年 10 月。
在线发布